

Construye | Proyecto Etapa 1. Selección de dataset para su procesamiento con PySpark

5/3/2026

10 Punto Posible

Intento 1



En progreso

SIGUIENTE: Presentar tarea

Agregar comentario

Se permiten intentos ilimitados**▼ Detalles**

Objetivo

Identificar una base de datos de Big Data para la aplicación de los conceptos aprendidos en el curso, iniciando con la manipulación básica de lectura y escritura de archivos con PySpark.



Instrucciones

Para esta actividad, realizarás una investigación cuyo objetivo es identificar un tema de investigación en la cual, exista un dataset que puedas trabajar a lo largo del curso. Este dataset deberá de tener por lo menos un tamaño de 1 GB (idealmente en formato tabular), relacionado con un tema de interés personal o profesional. Para lograrlo, se sugiere seguir los siguientes pasos:

Identifica un tema de interés. Reflexiona sobre tus áreas de interés profesional o personal (por ejemplo, sector salud, medio ambiente, economía, finanzas, deportes, tecnología, entre otros), y elige un tema que te motive a encontrar patrones ocultos que apoyen a la toma de decisiones futura en el área seleccionada.

Búsqueda del dataset. Realizar una investigación que te permita identificar repositorios de datos (de acceso abierto idealmente), en la que existan dataset relacionados al tema de interés seleccionado. Como base de tu investigación puedes acceder a repositorios reconocidos, como:

- Kaggle
- Google Cloud Public DataSets
- UCI Machine Learning Repository
- Bases de datos gubernamentales
- Bases de datos espaciales
- **El dataset seleccionado deberá de cumplir los siguientes criterios:**
 - Relacionado con tu tema de interés.
 - Tamaño mínimo de 1 GB. El tamaño máximo queda abierto, pero no se recomienda trabajar con bases de datos extremadamente grandes, ya que los recursos computacionales y los tiempos de procesamiento pueden ser muy altos (una recomendación no es sobrepasar 10 GB de datos).
 - Datos preferentemente en formato tabular (por ejemplo, CSV, SQL, entre otros).

Revisión del dataset: Descarga el dataset seleccionado y realiza un análisis inicial:

- Utilizando PySpark, se deberá de abrir la base de datos seleccionada
 - Examina la estructura de los datos (identificando estadísticas generales de la base, como número de columnas, número de registros, tipos de datos, registros con valores faltantes, columnas con valores faltantes, estadística descriptiva de los descriptores, como media, desviación estándar, moda, etc.)
 - Identifica si contiene datos relevantes para tu tema de investigación

Análisis: realiza un análisis del dataset seleccionado, incluyendo:

- Nombre y origen del dataset.

- Descripción general de su contenido, mostrando estadística general descriptiva a partir de gráficas.
- Indicar si la base de datos requiere ser pre-procesada, para corregir problemas que tenga la misma. Documentar que tipo de correcciones se tendrían que aplicar (en esta etapa no se espera que se apliquen las correcciones, solo se debe de hacer un análisis conceptual e indicar las etapas de corrección a aplicar, debidamente sustentadas).

Para la entrega deberá ser en documento en formato PDF, que contenga:

1. Carátula
2. Descripción del tema de interés: descripción del tema que se pretende abordar, planteando un objetivo general que se pretende alcanzar, claro y conciso.
3. Selección del dataset: Nombre y origen del dataset (se recomienda incluir un link al dataset de origen), tamaño global del dataset (en GB). El dataset debe de ser por lo menos de 1 GB.
4. Análisis del dataset: mostrar la estadística descriptiva del dataset, a través de gráficas. Dar una interpretación a la información que se obtenga del dataset, y documentar que tipo de correcciones requiere el dataset (eliminación de ruido, valores atípicos, valores nulos, etc.).

Longitud máxima del documento: 3 cuartillas.



Especificaciones de entrega

- **Modalidad:** En equipo.
- **Medio de realización/entrega:** En el botón Entrega, ubicado en la parte superior derecha de esta actividad.
- **Formato:** Documento PDF.
- **Nombre del entregable:** archivos de Big Data PySpark_Equipo#

IMPORTANTE:

- El uso de herramientas de inteligencia artificial deberá declararse de manera explícita; en ningún caso se deberá presentar como propio un producto generado total o parcialmente por dichas herramientas. Cuando se utilicen, deberá indicarse la herramienta y el modelo empleado en la entrega, así como la finalidad de su uso (revisión de redacción / formato del documento / generación de imágenes generación de código / depuración / optimización).
 - Ejemplo: OpenAI. (2026). ChatGPT (basado en GPT-4) [Modelo de lenguaje grande], utilizado para generación de código y depuración. <https://chat.openai.com/> (<https://nam04.safelinks.protection.outlook.com/?url=https%3A%2F%2Fchat.openai.com%2F&data=05%7C02%7Cveroguzman%40tec.mx%7C0ceb6bc9a203401f957608de9b4f2da>)

La responsabilidad final sobre el contenido entregado recae en el autor. El estudiante deberá asegurar que las soluciones presentadas se ajusten estrictamente a lo solicitado, evitando la inclusión de código innecesario, excesivamente complejo o no requerido. El incumplimiento de este criterio podrá derivar en penalizaciones en la evaluación de la actividad.



Criterios de evaluación

Tabla de criterios (Valor: 10%)

Criterio	Valor
Carátula	1 puntos
Descripción del tema de interés y objetivo general	3 puntos
Selección del dataset	3 puntos
Análisis del dataset	3 puntos



Recursos de apoyo

Recursos de apoyo que pueden ser de tu interés, cada uno te llevará a repositorios de datos

- <https://data.gov/>
- <https://www.gigasheet.com/sample-data>
- <https://datasetsearch.research.google.com/>
- <https://www.kaggle.com/>
- <https://www.tableau.com/learn/articles/free-public-data-sets>
- <https://archive.ics.uci.edu/>
- <https://datahub.io/collections>
- <https://www.datablist.com/learn/csv/download-sample-csv-files>
- <https://www.tablab.app/csv/sample>
- <https://www.earthdata.nasa.gov/>
- <https://opendata.cern.ch/search?q=&f=type%3ADataset&l=list&order=desc&p=1&s=10&sort=mostrecent>
- <https://apps.who.int/gho/data/node.home>
- <https://www.bfi.org.uk/industry-data-insights>
- <https://www.kdnuggets.com/datasets/index.html>
- <https://datacommons.org/>

Sitios web con repositorios recomendados:

1. <https://www.interviewquery.com/p/free-datasets>
2. <https://www.dataquest.io/blog/free-datasets-for-projects/>
3. <https://careerfoundry.com/en/blog/data-analytics/where-to-find-free-datasets/>
4. <https://www.quora.com/Data/Where-can-I-find-large-datasets-open-to-the-public>
5. https://hadoopilluminated.com/hadoop_illuminated/Public_Bigdata_Sets.html

▼ Ver rúbrica

Etapa1						
Criterios	Calificaciones					Puntuación
Carátula	Destacado	Sólido	Básico	Requiere mejorar	No presentó	/1
	Incluye todos los elementos: título del trabajo, nombre del estudiante, asignatura, docente, institución y fecha. Presentación clara y ordenada.	Incluye la mayoría de los elementos solicitados; presenta ligeros detalles de formato.	Incluye algunos elementos, pero faltan varios datos importantes.	Presenta pocos elementos o la información es poco clara.	No presenta carátula	
	1 pts	0.8 pts	0.6 pts	0.4 pts	0 pts	

Criterios	Calificaciones					Puntuación
Descripción del tema de interés y objetivo general	Destacado	Sólido	Básico	Requiere mejorar	No presentó	/3 pts
	El tema está claramente descrito y contextualizado. El objetivo general es claro, preciso, medible y coherente con el tema. Redacción clara y bien estructurada.	El tema está descrito adecuadamente así como el objetivo, con aspectos que se pueden mejorar en profundidad para una mejor descripción.	La descripción es básica; el objetivo es poco claro o demasiado general.	La descripción del tema es confusa o el objetivo está mal formulado.	No presenta la descripción ni el objetivo.	
	3 pts	2 pts	1 pts	0.5 pts	0 pts	
Selección del dataset	Destacado	Sólido	Básico	Requiere mejorar	No presentó	/3 pts
	Presenta claramente el nombre del dataset, origen, enlace al dataset, tamaño en GB (≥1 GB) y justifica su elección en relación con el tema.	Presenta nombre, origen y tamaño del dataset; el tamaño del dataset no es superior a 1 GB.	Presenta información parcial del dataset; faltan algunos datos (origen, enlace o tamaño).	Presenta información incompleta o el dataset no cumple el tamaño mínimo sugerido (muy inferior a 1 GB).	No presenta dataset	
	3 pts	2 pts	1 pts	0.5 pts	0 pts	
Análisis del dataset	Destacado	Sólido	Básico	Requiere mejorar	No presentó	/3 pts
	Presenta estadísticas descriptivas mediante varias gráficas adecuadas. Interpreta correctamente los resultados y describe claramente problemas del dataset (ruido, valores atípicos, valores nulos, etc.).	Presenta algunas gráficas y estadísticas descriptivas con interpretación general adecuada; identifica algunos problemas del dataset.	Presenta pocas gráficas o interpretación superficial; identifica de manera limitada problemas del dataset.	Presenta análisis muy limitado, sin interpretación clara o sin identificación adecuada de problemas del dataset.	No presenta análisis del dataset.	
	3 pts	2 pts	1 pts	0.5 pts	0 pts	




Recuerde que esta entrega contará para todos en su grupo Project Groups.

Elegir un tipo de presentación

Cargar

Más



Elija un archivo para cargar

o

 Foto de la cámara web

 Canvas Files



(<https://experiencia21.tec.mx/courses/663468/modules/items/41364961>)



(<https://experiencia21.tec.mx/courses/663468/modules/items/41364962>)