



INSTITUTO TECNOLÓGICO Y DE ESTUDIOS
SUPERIORES DE MONTERREY

***Etapas 1. Selección de dataset para su
procesamiento con PySpark***

Equipo 12

Carlos Eduardo Vega Campos - A01797803

Marco Emilio Jimenez Jimenez - A01797948

Martha Alicia Villalobos Facundo - A01840063

Jonathan Javier Monsalve Giraldo - A01840272

Análisis de grandes volúmenes de datos

Profesores: Iván Olmos Pineda - Luis Daniel Mendoza

3 de mayo del 2026

1. Tema de interés y objetivo general

La movilidad urbana densa genera grandes volúmenes de datos en tiempo real, reflejando dinámicas económicas, sociales y geográficas. Los registros de viajes en taxi son un ejemplo clave: cada viaje produce numerosas variables (tiempo, pago, zonas, distancia, tarifas, propinas). La New York City Taxi and Limousine Commission (TLC) publica estos registros mensualmente, siendo una fuente oficial y continua para el análisis de Big Data.

Objetivo general: Analizar viajes de Yellow Taxi en Nueva York (2024-2025) con PySpark y Big Data Analytics para identificar patrones temporales, geográficos y económicos de demanda, distancia, tarifa y propina.

Objetivos específicos: (i) Caracterizar distribución temporal de viajes (hora, día, estación); (ii) identificar zonas origen/destino más demandadas (usando Taxi Zone Lookup Table); (iii) modelar relación distancia, tarifa, propina y método de pago (para modelado predictivo); (iv) detectar y documentar anomalías (tarifas negativas, distancias cero, duraciones imposibles, nulos).

2. Selección y justificación del dataset

Nombre y origen: NYC TLC Yellow Taxi Trip Records, publicado por la New York City Taxi and Limousine Commission. ([Enlace](#)) Tamaño: 1.42 GB en disco (24 archivos Parquet mensuales más el catálogo de zonas en CSV), 89,892,322 registros.

Justificación: El conjunto de datos supera el requisito de la rúbrica (>1 GB), con 89.9 millones de registros, ideal para PySpark local. Ofrece heterogeneidad de tipos para ejercitar todos los módulos del curso y dos años para análisis comparativo. La fuente es un CDN público (garantizando reproducibilidad) y está en formato Parquet, que es columnar, más eficiente que CSV para procesamiento columnar en Spark y conserva tipos nativos.

3. Análisis exploratorio del dataset

El dataset fue cargado en PySpark para calcular número de registros, tipos de datos, valores nulos, percentiles y estadísticas descriptivas. La Figura 1 muestra un pico de demanda claro de martes a jueves entre las 17:00 y las 19:00 (más de 1 millón de viajes), con la menor actividad de lunes a jueves de 2:00 a 5:00. Viernes y sábados presentan un pico nocturno adicional de 22:00 a 1:00, indicando tráfico de ocio.






Fig 1. Heatmap 24x7 de conteo de viajes por hora del día y día de la semana.

La Figura 2 muestra la distribución logarítmica de fare_amount. La mediana es USD 13.55, con el p95 en USD 61.10 y el p99 en USD 79.30, indicando una cola larga. Un pico en USD 70 (tarifa plana JFK-Manhattan) es una moda secundaria. Esto justifica el filtrado posterior al p99.9 para eliminar *outliers* extremos, preservando la tarifa institucional del aeropuerto.




Según la Figura 3, solo los viajes pagados con tarjeta de crédito (`payment_type = 1`) reportan propinas reales (mediana USD 3.30, rango intercuartil USD 2 a 5, P95 aprox. USD 13). Las demás categorías tienen mediana cero porque las propinas en efectivo no se registran en el sistema. Este sesgo estructural debe considerarse en el análisis posterior.



Según la Figura 4, cinco columnas (`passenger_count`, `RatecodeID`, `store_and_fwd_flag`, `congestion_surcharge`, `Airport_fee`) tienen el mismo 17.47% de nulos (15,703,126 filas), lo que corresponde a la modalidad Flex Fare (`payment_type = 0`). Estos nulos son intencionales, ya que el viaje se cotiza por

adelantado sin activar el taxímetro. La estrategia es usar una bandera `is_flex_fare` en lugar de imputar los datos faltantes.



La correlación de Pearson ($r=0.01$) entre `trip_distance` y `fare_amount` en datos crudos es incorrecta (debería superar 0.8), debido a *outliers* extremos (máx. 398,608 millas y USD 863,372). Esto confirma la necesidad imperativa de limpiar los *outliers* en la Etapa 2 antes del modelado supervisado.

4. Problemas de calidad y correcciones propuestas

#	Problema detectado	Corrección propuesta
1	trip_distance con valores físicamente imposibles (máx. 398,608 millas).	Filtrar al rango [0, p99.9] o tope físico de 200 millas.
2	Variables monetarias con valores negativos (p. ej. mín. -USD 2,265 en total_amount) y máximos de seis cifras (USD 863,372)	Filtrar negativos y aplicar tope p99.9
3	passenger_count con valores fuera del rango documentado (0, 7, 8, 9).	Imputar a 1 (moda y mediana del dataset).
4	59 timestamps fuera de 2024-2025 (años 2002, 2007-2009, 2023, 2026).	Filtrar al rango temporal declarado.
5	21 registros 2024 con cbd_congestion_fee no nulo (cargo vigente desde 2025-01-05).	Imputar a 0.0.
6	Nulos estructurales en cbd_congestion_fee (46.4 % del total, columna ausente en 2024).	Imputar a 0.0 para registros 2024.
7	Patrón sincronizado de nulos Flex Fare en 5 columnas (17.47 %, 15.7 M filas, mismas filas).	Marcar bandera is_flex_fare = (payment_type == 0); no imputar.
8	Zonas placeholder 264 y 265 (Unknown, N/A) en el top 10 de origen y destino.	Excluir de análisis geográficos; conservar en agregados globales.
9	Matriz de Pearson distorsionada por outliers ($r \approx 0.01$ entre distancia y tarifa).	Recalcular tras correcciones 1, 2, 3 y 10; comparar con Spearman.
10	Viajes con trip_distance = 0 y fare_amount > 0 (cluster vertical en scatter).	Filtrar o imputar distancia desde tarifa (~USD 2.50/mi).

Las correcciones 1, 2, 4 y 10 de la tabla (negativos, máximos, timestamps fuera de rango, distancia=0 con tarifa>0) son destructivas y se aplican en una sola pasada con un único filtro. Se mide el porcentaje total de filas removidas y se exige que sea <1% del dataset; si excede, se revisa el umbral. Las correcciones 3, 5, 6, 7 (imputaciones y banderas) se aplican después sobre el dataset ya filtrado.

Referencias

Apache Software Foundation. (2025). *Apache Spark 4.1.1 Documentation*.
<https://spark.apache.org/docs/latest/>

Google. (2026). *Gemini Model 3.1* [Modelo de lenguaje grande], utilizado como apoyo para la selección preliminar del dataset. <https://gemini.google.com/>

New York City Taxi and Limousine Commission. (2026). *TLC Trip Record Data: Yellow Taxi Trip Records 2024-2025* [Conjunto de datos]. NYC.gov.
<https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>