

Construye | Proyecto Etapa 2. Selección de técnica de muestreo para la construcción de muestra inicial

5/17/2026



Intento 1



En progreso

SIGUIENTE: Presentar tarea

Agregar comentario

Se permiten intentos ilimitados

▼ Detalles



Objetivo

Identificar y aplicar técnicas de muestreo orientadas al Big Data, a través de la implementación de código basado en PySpark, que te permitan construir una muestra representativa de la población objetivo, definida para tu proyecto de investigación.



Instrucciones

En esta actividad, realizarás una investigación profunda que te permita construir una muestra representativa (M), que contenga un conjunto de datos necesarios y suficientes para poder extraer patrones de interés, válidos, para la población objetivo de tu investigación (P), usando para ello la base de datos (D) que recolectaste en tu actividad previa. La dimensión de la muestra a construir dependerá de las características generales de la población a investigar, para lo que será necesario identificar variables de caracterización que permitan entender los comportamientos conocidos que se tienen de la población. A partir de dicho conocimiento, se podrá definir una estrategia de muestreo para la construcción de la muestra M.

Para lograrlo, se sugiere seguir los siguientes pasos:

- 1. Caracterización de la población.** Realizar una investigación sobre la población (P) objetivo de la investigación, que permita conocer aquellos comportamientos habituales (variables de caracterización) que se presentan en P. Una vez identificadas las variables, se debe tener en claro cuáles son sus valores típicos (dominio de cada variable), rangos de valores válidos, así como cualquier otra información que ayude a comprender su comportamiento (estadísticas típicas de comportamiento). A partir de lo anterior, se debe crear una tabla que describa a cada variable, dominio de la variable, estadística conocida de la variable, así como comentarios adicionales que sean relevantes para su comprensión.
- 2. Particionamiento.** Para esta segunda etapa y utilizando las variables de caracterización identificadas en la etapa previa, diseñar el proceso de particionamiento que será usado para particionar D, de tal forma que se creen subconjuntos de particionamiento a través de las variables de caracterización que has identificado. Por ejemplo, supongamos que se identificaron dos variables de caracterización, A y B, y cada una de ellas con dos posibles valores (A puede tomar los valores {a,b} con probabilidades de ocurrencia {0.3, 0.7} respectivamente, y B puede tomar los valores {c,d} con probabilidades de ocurrencia de {0.2, 0.8} respectivamente). Con lo anterior, se generan cuatro combinaciones de particionamiento:
 - **Combinación A -> a, B -> c:** con probabilidad de ocurrencia de 0.06
 - **Combinación A -> a, B -> d:** con probabilidad de ocurrencia de 0.24
 - **Combinación A -> b, B -> c:** con probabilidad de ocurrencia de 0.14
 - **Combinación A -> b, B -> d:** con probabilidad de ocurrencia de 0.56

Lo anterior genera una serie de reglas de particionamiento que será aplicado para dividir la base de datos original. Se debe documentar técnicamente cada una de las características que debe tener cada partición.

- 3.** Para cada combinación identificada en el paso anterior, se debe de generar un particionamiento de la base de datos original D, de tal forma que se deben de seleccionar las instancias que cumplen las reglas de partición de cada conjunto. Para ello y para cada regla de particionamiento generado, realizar lo siguiente:
 - Crear un código (en un Jupyter Notebook) que te permita filtrar y recuperar registros de la base de datos D que cumplan la regla de particionamiento que se está trabajando. El cuaderno de Jupyter Notebook, deberá de estar organizado de la

siguiente forma: un título, una breve descripción de la base de datos D que se está procesando, así como la descripción de las reglas de particionamiento construidas, una sección en la cual se cargan los datos (basado en PySpark), y una serie de bloques de código en las cuales se extraen submuestras que cumplen las reglas de particionamiento generadas.

- Se deberá probar el código generado de tal forma que se puedan extraer de la base de datos D submuestras asociadas a las reglas de particionamiento que se han construido (**NOTA:** para esta etapa, solo se pide verificar el correcto funcionamiento de su código; las muestras que se obtengan solo serán de prueba, ya que, en una etapa posterior, este código será usado para construir conjuntos de entrenamiento y prueba cumpliendo los criterios desarrollados en esta etapa).
4. **Técnica de muestreo a aplicar por partición:** Una vez establecidas las reglas de particionamiento a emplear, se deberá de definir la técnica de muestreo que se aplicará a cada partición, de tal forma que se pueda recuperar un conjunto de instancias para la construcción de conjuntos de entrenamiento y prueba para la etapa de aprendizaje (Nota: no se pide que se generen en esta etapa dichos conjuntos, solo se debe tener en claro que tipo de muestreo se aplicará para recuperar instancias de las particiones generadas). Se debe de argumentar porque el tipo de partición seleccionado evita en lo más posible introducir sesgos al momento de seleccionar las instancias (garantizando con ello que la muestra sea representativa para la partición).

Evidencia:

Documento en formato PDF, que contenga:

1. **Portada** con datos completos de integrantes del equipo.
2. Documento dividido por secciones, en las se da respuesta a cada uno de los puntos anteriormente descritos:
 1. **Caracterización de la población:** tabla que describe cada una de las variables de caracterización identificadas en su investigación de la población. La tabla debe contener por lo menos las columnas:
 - nombre de la variable,
 - dominio de la variable (posibles valores que se pueden tener asociados a la variable),
 - descripción estadística conocida de la variable (por ejemplo, valores de media, varianza, frecuencia de ocurrencia de los valores, etc),
 - así como una columna de comentarios adicionales donde se añada información adicional que ayude a entender el comportamiento de la variable.
 2. **Particionamiento:** descripción del proceso de particionamiento aplicable al conjunto de datos D. Se deben describir las combinaciones de particionamiento que se pueden generar a partir de las variables de caracterización identificadas. Además, se debe señalar las probabilidades de ocurrencia de cada combinación obtenida, la cual se calculará a partir de la probabilidad de ocurrencia combinada de las particiones bajo las diferentes reglas de particionamiento generadas.
 3. Un **enlace a un archivo Jupyter Notebook**, que contenga la solución del paso 3 (código de implementación de la etapa de particionamiento). En el mismo cuaderno del Jupyter Notebook se deberán de mostrar ejemplos de cómo se extraen muestras ejemplo de cada regla de particionamiento que se han propuesto en el paso previo. Nota: el archivo Jupyter Notebook, así como la base de datos que se procesa, se deberá de subir a Google Drive, y compartir el acceso a dicho archivo.
 4. **Descripción detallada el proceso de muestreo a usar para recuperar instancias de cada partición.** Se debe explicar que técnica se empleará, dando una justificación detallada de porqué es adecuada para recuperar y construir muestras representativas.

Longitud máxima del documento: 10 cuartillas.



Especificaciones de entrega

- **Modalidad:** En equipo
- **Medio de realización/entrega:** En el botón Entrega, ubicado en la parte superior derecha de esta actividad.
- **Formato:** el archivo Jupyter Notebook, así como la base de datos que se procesa, se deberá de subir a Google Drive, y compartir el acceso a dicho archivo.
- **Nombre del entregable:** Evidencia1_Equipo#

IMPORTANTE:

- El uso de herramientas de inteligencia artificial deberá declararse de manera explícita; en ningún caso se deberá presentar como propio un producto generado total o parcialmente por dichas herramientas. Cuando se utilicen, deberá indicarse la herramienta y el modelo empleado en la entrega, así como la finalidad de su uso (revisión de redacción / formato del documento / generación de imágenes generación de código / depuración / optimización).
 - Ejemplo: OpenAI. (2026). ChatGPT (basado en GPT-4) [Modelo de lenguaje grande], utilizado para generación de código y depuración. <https://chat.openai.com/> (<https://nam04.safelinks.protection.outlook.com/?url=https%3A%2F%2Fchat.openai.com%2F&data=05%7C02%7Cveroguzman%40tec.mx%7C0ceb6bc9a203401f957608de9b4f2da>)

La responsabilidad final sobre el contenido entregado recae en el autor. El estudiante deberá asegurar que las soluciones presentadas se ajusten estrictamente a lo solicitado, evitando la inclusión de código innecesario, excesivamente complejo o no requerido. El incumplimiento de este criterio podrá derivar en penalizaciones en la evaluación de la actividad.

Criterios de evaluación

Consulta la rúbrica para conocer a detalle los criterios de evaluación.

Tabla de criterios (Valor: 20%)

Criterio	Valor
Carátula	2 puntos
Caracterización de la población	4 puntos
Particionamiento del conjunto de datos	4 puntos
Archivo Jupyter Notebook, que contenga la solución del paso 3 (código de implementación de la etapa de particionamiento)	5 puntos
Descripción e implementación del proceso de muestreo	5 puntos

Ver rúbrica

Etapa2						
Criterios	Calificaciones					Puntaje
Carátula	Destacado Incluye todos los elementos requeridos: título, nombre del estudiante, asignatura, docente, institución y fecha. Presentación clara, ordenada y profesional. 2 pts	Sólido Incluye la mayoría de los elementos requeridos; pequeños detalles de formato o información. 1.5 pts	Básico Incluye algunos elementos pero faltan varios datos importantes. 1 pts	Requiere mejorar Presenta pocos elementos o la información es confusa. 0.5 pts	No presentó No presenta carátula. 0 pts	2

Criterios	Calificaciones					Puntuación
Caracterización de la población	Destacado	Sólido	Básico	Requiere mejorar	No presentó	/4 puntos
	Presenta una tabla completa con todas las variables de caracterización. Incluye nombre de variable, dominio, estadística descriptiva (media, varianza, frecuencia, etc.) y comentarios relevantes que facilitan la interpretación de las variables. 4 pts	Presenta la tabla con la mayoría de los elementos solicitados y estadísticas descriptivas adecuadas, aunque con menor profundidad en comentarios o análisis. 3 pts	Presenta la tabla con información básica; algunas columnas están incompletas o con descripción limitada. 2 pts	Tabla incompleta o con información poco clara; falta la mayor parte del análisis estadístico. 1 pts	No presenta caracterización de la población. 0 pts	
Particionamiento del conjunto de datos	Destacado	Sólido	Básico	Requiere mejorar	No presentó	/4 puntos
	Describe claramente el proceso de particionamiento del conjunto de datos. Identifica todas las combinaciones posibles de las variables de caracterización y calcula correctamente las probabilidades de ocurrencia de cada partición. 4 pts	Describe el proceso de particionamiento y algunas combinaciones de variables; las probabilidades están presentes pero con menor detalle o precisión. 3 pts	Presenta una descripción básica del particionamiento; las combinaciones o probabilidades están incompletas o poco justificadas. 2 pts	Descripción confusa o incompleta del particionamiento; no se muestran claramente las probabilidades de ocurrencia. 1 pts	No presenta el proceso de particionamiento. 0 pts	


Criterios	Calificaciones					Puntuación
Jupyter Notebook con implementación del particionamiento	Destacado	Sólido	Básico	Requiere mejorar	No presentó	/5 puntos
	Proporciona enlace funcional al Jupyter Notebook en Google Drive. El código implementa correctamente el particionamiento y muestra ejemplos claros de extracción de muestras para cada regla de particionamiento. El código está bien organizado y documentado. 5 pts	Presenta el enlace al notebook con implementación funcional del particionamiento y algunos ejemplos de extracción de muestras, aunque con menor documentación o con falta de alguna etapa de implementación. 4 pts	El notebook contiene implementación parcial o ejemplos limitados; la documentación del código es mínima. 3 pts	El notebook presenta errores importantes, el enlace es limitado o el código no demuestra claramente el particionamiento. 2 pts	No presenta el notebook o el enlace no es accesible. 0 pts	
Descripción e implementación del proceso de muestreo	Destacado	Sólido	Básico	Requiere mejorar	No presentó	/5 puntos
	Explica detalladamente la técnica de muestreo utilizada, con justificación clara de su pertinencia para obtener muestras representativas. El notebook incluye implementación documentada del proceso de muestreo sobre las particiones generadas. 5 pts	Explica la técnica de muestreo y presenta implementación funcional en el notebook, aunque con menor nivel de detalle o justificación o con falta de alguna etapa de implementación. 4 pts	Presenta una explicación básica del método de muestreo y una implementación parcial. 3 pts	La explicación es superficial o la implementación es incompleta o poco clara. 2 pts	No presenta descripción ni implementación del muestreo. 0 pts	

Recuerde que esta entrega contará para todos en su grupo Project Groups.

Elegir un tipo de presentación

Cargar

Más



Elija un archivo para cargar

o

 Foto de la cámara web

 Canvas Files



(<https://experiencia21.tec.mx/courses/663468/modules/items/41365001>)



(<https://experiencia21.tec.mx/courses/663468/modules/items>)