



INSTITUTO TECNOLÓGICO Y DE ESTUDIOS
SUPERIORES DE MONTERREY

***Proyecto Etapa 2. Selección de técnica de
muestreo para la construcción de muestra
inicial***

Equipo 12

Carlos Eduardo Vega Campos - A01797803

Marco Emilio Jimenez Jimenez - A01797948

Martha Alicia Villalobos Facundo - A01840063

Jonathan Javier Monsalve Giraldo - A01840272

Análisis de grandes volúmenes de datos

Profesores: Iván Olmos Pineda - Luis Daniel Mendoza

17 de mayo del 2026

1. Planteamiento del problema de muestreo

El objetivo de esta etapa es construir una muestra M representativa de la población objetivo P a partir del dataset D recolectado en la Etapa 1, aplicando técnicas de muestreo orientadas a Big Data e implementadas en PySpark. La rúbrica exige caracterizar la población, identificar variables de caracterización con sus dominios y estadísticas conocidas, diseñar reglas de particionamiento, calcular probabilidades de ocurrencia por partición y describir la técnica de muestreo aplicada.

Se adjunta el archivo [Jupyter](#) en google drive con la solución. El documento incluye la descarga de datos en tiempo real, omitiendo la necesidad de archivos adicionales en Drive.

1.1 Población objetivo, población analítica y dataset observado

La población objetivo P se define como todos los viajes realizados en taxis amarillos medallón en Nueva York durante 2024-2025, registrados por los sistemas TLC/TPEP bajo cualquier régimen tarifario (medido, tarifa plana de aeropuerto, Flex Fare). P no incluye servicios FHV (Uber, Lyft, Via) ni propinas en efectivo, que TPEP no captura por diseño.

El dataset observado D corresponde al subconjunto de viajes procesados exitosamente por los sistemas TPEP y publicados por la TLC en formato Parquet. D contiene 89,892,322 registros, ocupa 1.42 GB en disco y abarca enero 2024 a diciembre 2025.

D no representa fielmente a P . La Etapa 1 documentó cinco fuentes estructurales de sesgo: outliers físicamente imposibles, censura de propinas en efectivo, 17.47% de nulos estructurales del régimen Flex Fare, cambios de esquema mid-period y errores temporales.

Para acotar el alcance del muestreo se introduce el concepto de población analítica P^* , definida como el subconjunto de viajes de P con timestamps válidos, montos no negativos, distancias físicamente plausibles y sin contradicciones evidentes entre distancia y tarifa. La muestra M se construye sobre D limpio, que es un marco de observación razonablemente consistente con P^* en las dimensiones comparables contra fuentes históricas. La distinción P , P^* , D , M se mantiene a lo largo del documento.

2. Caracterización de la población P

La identificación de variables de caracterización se apoya en estudios académicos previos y reportes oficiales de la TLC que han descrito el comportamiento histórico de los viajes en taxis amarillos en Nueva York. Esta evidencia externa permite construir referencias contra las cuales contrastar D y evita que el diseño del muestreo dependa solo de las distribuciones internas del dataset.

2.1 Fuentes históricas utilizadas como referencia

Fuente	Tipo y periodo	Estadísticas utilizadas
TLC HAIL Market Analysis (2013)	Reporte oficial TLC Datos 2010-2013	95% de pickups Yellow Taxi en Manhattan Core + aeropuertos. 5% en outer boroughs (Bronx, Brooklyn, Queens, Staten Island).

Fuente	Tipo y periodo	Estadísticas utilizadas
TLC Flex Fare Pilot Evaluation Report (2023)	Reporte oficial TLC Datos 2019-2023	Mean fare metered: USD 13.47. Mean distance metered: 3.15 millas. Port Authority prohíbe e-hail (Flex) en aeropuertos.
TLC Annual Report 2024 (2025)	Reporte oficial TLC Datos 2024	Más de 41 millones de viajes Yellow Taxi en 2024. Régimen Flex Fare adoptado en septiembre 2024. Cargo CBD vigente desde 2025-01-05.
Safikhani et al. (2020)	Peer-reviewed Int. J. Forecasting Datos 2015	Picos de demanda 7-9 AM (commuting) y 16-20 PM (vespertino, máximo absoluto). Valle nocturno 0-5 AM. Patrones de fin de semana cualitativamente distintos al laboral.
Riascos y Mateos (2020)	Peer-reviewed Scientific Reports Datos 2009-2015	Distribución por distancia geográfica: 41.33% < 1.12 mi, 57.49% entre 1.12 y 12.43 mi, 1.18% > 12.43 mi.
Donkor (2020), Stanford	Working paper Stanford GSB Datos 2017-2019	Credit share entre pagos medidos: 75-78%. Censura de propinas en efectivo: TPEP no las captura.
Moorthy (2025)	Preprint arXiv Datos TLC 2024	Filtrar outliers extremos antes de cualquier análisis. Correlación distancia-tarifa post-limpieza debe superar 0.7.
TLC Data Dictionary (2025)	Documentación oficial Esquema vigente	Códigos de payment_type (0=Flex, 1=tarjeta, 2=efectivo, 3-6=otros). Códigos de RatecodeID (1=Estándar, 2=JFK plana, 3=Newark, etc.).

Tabla 2.1. Estudios y reportes consultados. Referencias completas en formato APA 7 en la sección 7.

2.2 Variables de caracterización seleccionadas

Se eligen cuatro variables como ejes de particionamiento y dos banderas auxiliares para validación. La selección no es arbitraria: cada variable aparece de forma recurrente en la evidencia histórica de la tabla 2.1 y captura una dimensión estructural distinta del comportamiento de los viajes en Yellow Taxi.

Variable	Tipo	Dominio	Estadística conocida de P	Comentarios
pu_macro_zone	Categórica	airport, manhattan, outer_borough, unknown	~95% Manhattan + airport. ~8% airport solo. ~5% outer borough. Fuente: TLC HAIL 2013.	Colapsa 265 zonas TLC con precedencia airport > unknown > manhattan > outer.
payment_group	Categórica	credit, cash, flex, other	Credit share metered: 75-78% (Donkor 2020).	payment_type 0=Flex, 1=credit, 2=cash, 3-6=other.

Variable	Tipo	Dominio	Estadística conocida de P	Comentarios
			Flex Fare ~17% del dataset (TLC 2024).	Separa Flex por taxímetro inactivo y cash por censura de propinas.
day_hour_bucket	Temporal	weekday_am, weekday_pm_peak, late_night, weekend, other	Picos 7-9 AM y 16-20 PM. Valle 0-5 AM. Patrones de fin de semana distintos. Fuente: Safikhani 2020.	Resuelve solapamiento con cadena when con short-circuit. Bucket other recoge horario laboral no-pico.
trip_distance_bin	Discretizada	short (<1.12 mi) medium (1.12-12.43 mi) long (>12.43 mi)	41.33% / 57.49% / 1.18% por bin. Fuente: Riascos y Mateos 2020.	Umbral convertidos de 1.8 km y 20 km. La distribución empírica de D difiere por definición de medida y displacement FHV.
is_flex_fare	Bandera	true / false	Validación, no participa del estrato.	Identifica el régimen Flex sin recurrir al código numérico.
cbd_period_flag	Bandera	pre_cbd / post_cbd	Validación regulatoria. Frontera 2025-01-05.	Separa antes y después de la entrada del cargo CBD.

Tabla 2.2. Variables de caracterización. Las primeras cuatro componen el estrato compuesto; las dos banderas se conservan para validación posterior.

El estrato compuesto `stratum_id` se define como la concatenación de las cuatro primeras variables. La cardinalidad teórica es de $4 \times 4 \times 5 \times 3 = 240$ combinaciones. La sección 4 cuantifica la cardinalidad efectiva y enumera todas las combinaciones con sus probabilidades de ocurrencia empíricas.

3. Validación histórica de D contra fuentes externas

Antes de construir la muestra, contrastamos la distribución empírica del dataset D contra los valores históricos conocidos de P de la tabla 2.1. El propósito es responder dos preguntas operativas: existen desviaciones materiales entre D y P, y si existen, son sesgo de muestreo o cambios reales del periodo 2024-2025.

3.1 Limpieza previa: definición de P*

Antes de validar contra fuentes externas se aplican los filtros e imputaciones documentados en Etapa 1 para producir D limpio, implementación operativa de P*. Los filtros destructivos

acotan tpep_pickup_datetime al rango [2024-01-01, 2026-01-01), fare_amount a [0, 1000] USD, total_amount a [0, 1200] USD, trip_distance a [0, 200] millas, y descartan registros con distancia=0 y tarifa positiva. D pasa de 89,892,322 a 84,437,138 registros, con pérdida combinada de 6.07%. La pérdida supera la meta aspiracional de Etapa 1 (1.5%) pero se acepta como hallazgo: las anulaciones contables representan aproximadamente 4% del dataset, una fracción no anticipada al fijar la meta. Conservarlas distorsionaría las medias y medianas de tarifa que validamos en esta misma sección.

Sobre D filtrado se aplican imputaciones para nulos estructurales (passenger_count fuera de rango a 1, cbd_congestion_fee pre-2025 a 0, Airport_fee y congestion_surcharge nulos a 0, RatecodeID nulo a código sintético 99, store_and_fwd_flag nulo a F). Los imputados para Flex Fare son codificación operativa, no mediciones reales del taxímetro; la bandera is_flex_fare distingue este régimen.

3.2 Resultados de la validación histórica

Sobre D limpio se calculan las métricas comparables con las fuentes de la tabla 2.1. Los resultados se reportan junto con el umbral esperado, la tolerancia acordada y el estado OK/FAIL:

Métrica	Esperado	Observado	Tolerancia	Estado
Manhattan + airport pct	95.00%	94.92%	±3 pp	OK
Airport pct	8.00%	7.43%	±2 pp	OK
Outer borough pct	5.00%	4.83%	±3 pp	OK
Mean fare metered (USD)	13.47	19.66	±10%	FAIL
Mean distance metered (mi)	3.15	3.41	±15%	OK
Distance short pct	41.33%	26.81%	±5 pp	FAIL
Distance medium pct	57.49%	67.63%	±5 pp	FAIL
Distance long pct	1.18%	5.55%	±5 pp	OK
Credit share metered (pct)	76.50%	86.33%	±5 pp	FAIL
Correlación distancia-tarifa (metered)	> 0.70	0.930	floor 0.70	OK

Tabla 3.2. Validación histórica de D contra fuentes externas. 6 OK, 4 FAIL sobre 10 métricas comparables, contando la correlación distancia-tarifa como métrica validada. La correlación post-limpieza confirma la integridad estructural del dataset filtrado.

3.3 Interpretación: cambios reales del periodo, no sesgo de muestreo

Los 4 FAIL no apuntan a un sesgo del muestreo, a una falla de la limpieza ni a un problema del diseño del estrato. Todos tienen atribución externa documentable:

Mean fare metered (FAIL +46%). El benchmark TLC Flex Fare 2023 se construyó sobre datos 2018-2022. Tres cambios acumulativos explican el +46%: alza tarifaria TLC aprobada en noviembre 2022 y vigente a partir de fines de 2022 (~+23% en ticket promedio), cargo CBD de USD 0.75 desde enero 2025 aplicable a 88% de pickups, e inflación 2022-2025 (12-15%).

Distance bins (FAIL en short y medium). Riascos y Mateos 2020 midieron distancia zona-a-zona (centroide), mientras trip_distance en TLC viene del odómetro e incluye

desvíos. Además, los viajes cortos intra-Manhattan migraron a servicios FHV (Uber, Lyft) entre 2014 y 2024.

Credit share metered (FAIL +9.8 pp). Donkor analizó 2017-2019. Entre 2020 y 2025 la pandemia aceleró el uso de tarjeta y el mandato TLC de capacidad obligatoria de tap-to-pay post-2022 es consistente con la tendencia observada. Es tendencia social documentada, no sesgo del muestreo.

Las desviaciones se interpretan como cambios reales del periodo. La correlación distancia-tarifa de 0.930 confirma que la limpieza restauró la relación estructural distancia-tarifa que Etapa 1 había visto colapsada en 0.01 sobre datos crudos. La conclusión operativa es que D se considera un marco administrativo razonablemente consistente con la población analítica P^* de viajes Yellow Taxi válidos 2024-2025 en las dimensiones comparables. El muestreo de la sección 5 usa la distribución empírica p_D del estrato sin ajuste correctivo contra fuentes históricas anteriores al periodo del dataset.

4. Particionamiento y probabilidades de ocurrencia

Cada celda del estrato compuesto `stratum_id` es una regla de particionamiento que el muestreo trata de forma independiente. Esta sección enumera la cardinalidad efectiva, calcula las probabilidades de ocurrencia y analiza la dependencia entre las variables de caracterización.

4.1 Cardinalidad del estrato

La cardinalidad teórica del estrato compuesto es:

$$|\text{stratum_id}| = |\text{pu_macro_zone}| \times |\text{payment_group}| \times |\text{day_hour_bucket}| \times |\text{trip_distance_bin}|$$

$$|\text{stratum_id}| = 4 \times 4 \times 5 \times 3 = 240 \text{ combinaciones}$$

Sobre D limpio (84,437,138 registros) las 240 combinaciones teóricas están pobladas con al menos 53 registros. No hay celdas vacías. Las combinaciones con menor n_D (entre 53 y 80 registros) corresponden al patrón `airport x flex x * x short`, lo cual es consistente con que Port Authority prohíbe e-hail en aeropuertos. Estas celdas son estructuralmente raras pero no vacías.

4.2 Probabilidades de ocurrencia

Se presentan dos formas complementarias de la probabilidad por celda, ambas mencionadas en la rúbrica:

Probabilidad por producto de marginales: $p_{\text{product}}(s) = P(\text{pu_macro_zone}=a) \times P(\text{payment_group}=b) \times P(\text{day_hour_bucket}=c) \times P(\text{trip_distance_bin}=d)$. Es la probabilidad teórica que tendría la celda si las cuatro variables fueran independientes. Corresponde al patrón del ejemplo de la rúbrica.

Probabilidad empírica conjunta: $p_D(s) = n_D(s) / n_{\text{total}}$, donde $n_D(s)$ es el conteo observado de la combinación en D limpio.

Presentamos ambas y usamos p_D para la asignación de fracciones de muestreo porque las cuatro variables no son independientes en este dataset, y los datos lo confirman. Los cinco estratos con mayor dependencia positiva (ratio p_D / p_{product} mayor que 1) son:

stratum_id	n_D	p_D	ratio p_D / p_product
airport other weekday_pm_peak long	21,801	0.000258	18.25
airport other weekend long	20,360	0.000241	16.78
airport other late_night long	7,172	0.000085	16.42
airport other other long	25,469	0.000302	15.79
outer_borough flex late_night long	41,345	0.000490	14.52

*Tabla 4.1. Estratos con mayor dependencia positiva entre variables. El ratio mide cuánto se separa la celda observada del modelo de independencia. Cuatro de los cinco estratos son airport x other x * x long: los viajes largos desde aeropuerto se concentran en payment_type 3 (no-cargo) y 4 (disputa).*

El bucket payment_group = other dentro del estrato airport x * x * x long (82,283 registros) se compone en 80.1% de payment_type 4 (disputas) y 19.9% de payment_type 3 (no-cargo). Una interpretación plausible es que los viajes largos desde aeropuerto presentan una proporción desproporcionadamente alta de impugnaciones y cargos cero por efecto del monto: la tarifa plana JFK arranca en USD 70 post-alza 2022 y puede acercarse a USD 100 con tolls, CBD y propina. La codificación no es exclusiva de aeropuertos pero se concentra ahí por la fricción comercial sobre tickets altos.

Si hubiéramos usado p_product para asignar fracciones, estos cinco estratos quedarían sub-muestreados por factor 14 a 18. La empírica p_D los preserva en su proporción real.

4.3 Concentración del estrato

Los cinco estratos dominantes en D concentran aproximadamente 45% del dataset y comparten el patrón manhattan x credit x * x medium o short. El más frecuente, manhattan|credit|other|medium, agrupa 11,515,883 viajes (13.64%). Los demás del top cinco son manhattan|credit|weekday_pm_peak|medium (10.76%), manhattan|credit|weekend|medium (9.69%), manhattan|credit|other|short (6.44%) y manhattan|credit|weekday_am|medium (5.62%). El perfil característico del Yellow Taxi 2024-2025 es pickup en Manhattan, pago con tarjeta y distancia media.

En el otro extremo, los estratos más raros poblados tienen del orden de 50 a 100 registros. Con un muestreo proporcional puro, una celda de 53 registros recibiría $53 \times (5,000,000 / 84,437,138) = 3$ filas en la muestra final, cantidad insuficiente para cualquier análisis estadístico. La técnica de la siguiente sección introduce un piso mínimo para evitar la pérdida de estos perfiles.

5. Técnica de muestreo por partición

La rúbrica solicita justificar la técnica de muestreo elegida para extraer instancias de las particiones generadas. El profesor enfatizó en la sesión síncrona que el muestreo aleatorio simple aislado es riesgoso en Big Data y que el mínimo recomendado es muestreo estratificado, con consideraciones adicionales para variables continuas y atención a la representatividad de los conjuntos resultantes.

5.1 Técnica seleccionada: muestreo estratificado con piso mínimo por estrato

Aplicamos muestreo estratificado sin reemplazo con asignación proporcional a p_D y piso mínimo por estrato. La fórmula determina el tamaño objetivo por celda:

$$\text{target_n}(s) = \min(n_D(s), \max(\text{MIN_PER_STRATUM}, \text{round}(N_M \times p_D(s))))$$

$$\text{fraction}(s) = \text{target_n}(s) / n_D(s)$$

donde $n_D(s)$ es el conteo de la celda s en D limpio, $p_D(s)$ es su probabilidad empírica, N_M es el tamaño objetivo de la muestra global y MIN_PER_STRATUM es el piso mínimo de filas por celda. El comportamiento de la fórmula se descompone en tres categorías de estrato:

Categoría	Condición	target_n(s)	Interpretación
Estrato muy raro	$n_D < \text{MIN_PER_STRATUM}$	n_D (se toma completo, fraction = 1.0)	Celdas como airport x flex x * x short con 50-80 filas. Sin piso recibirían 3-5 filas.
Estrato elevado por el piso	$n_D \geq \text{MIN}$ y $\text{round}(N_M \times p_D) < \text{MIN}$	MIN_PER_STRATUM	El piso eleva el muestreo por encima de la asignación proporcional pura.
Estrato dominante o medio	$\text{round}(N_M \times p_D) \geq \text{MIN}$	$\text{round}(N_M \times p_D)$	Asignación proporcional clásica.

Tabla 5.1. Comportamiento de la fórmula por categoría de estrato.

5.2 Justificación de los parámetros

$N_M = 5,000,000$ (aproximadamente 5.92% de D limpio). Suficientemente grande para que el estrato dominante manhattan x credit x other x medium reciba aproximadamente 682,000 registros. Suficientemente pequeño para caber en el driver de Spark con holgura. Muestras del orden del 5% al 10% del dataset capturan los patrones globales sin sub-muestreo dañino.

$\text{MIN_PER_STRATUM} = 500$. Con $n = 500$ y $p = 0.5$, el intervalo de confianza al 95% para una proporción es ± 4.4 puntos porcentuales. Estratos menores producirían estimadores con intervalos demasiado anchos.

5.3 Por qué no muestreo aleatorio simple

Un muestreo aleatorio simple sobre 84.4 millones de registros sobre-representaría los perfiles dominantes (Manhattan x tarjeta x distancia media: 45% del dataset) y dejaría invisibles los perfiles raros. Riascos y Mateos 2020 documentan la naturaleza heavy-tail de los pickups en NYC, lo cual justifica el muestreo estratificado. El piso mínimo protege los perfiles raros sin distorsionar la proporcionalidad de los dominantes.

6. Implementación en PySpark y resultados

El notebook etapa2.ipynb implementa el muestreo descrito en la sección 5 sobre los 89.9 millones de registros del dataset. Esta sección documenta los resultados ejecutados y muestra los ejemplos por regla de particionamiento que solicita la rúbrica.

6.1 Construcción de la muestra M

La extracción emplea *sampleBy* de PySpark para aplicar fracciones de muestreo específicas por regla de particionamiento. El diccionario de fracciones se genera en el *driver* tras calcular *p_D* mediante *groupBy*, usando una semilla fija para asegurar la reproducibilidad.

```
M = df_feat.stat.sampleBy('stratum_id', fractions, seed=42).cache()
```

Los parámetros y resultados son:

Concepto	Valor
D crudo	89,892,322
D limpio (P*)	84,437,138
N_M (tamaño objetivo)	5,000,000
MIN_PER_STRATUM	500
Reglas de particionamiento (estratos poblados)	240 / 240
Estratos completos (fraction = 1.0)	30
Estratos elevados por el piso	80
Estratos en asignación proporcional	130
Tamaño efectivo de M	5,029,725 (+0.59% sobre N_M)

Tabla 6.1. Resultados de la construcción de M. La inflación del 0.59% refleja el costo de proteger los estratos raros que un muestreo proporcional puro habría perdido.

6.2 Validación de representatividad de M

Se re-aplican las métricas de la tabla 3.2 sobre M para verificar que el muestreo no introduce sesgo nuevo. La diferencia absoluta es de medio punto porcentual o menos en todas las métricas:

Métrica	D limpio	M	Diferencia
Manhattan + airport pct	94.92	94.50	-0.43
Airport pct	7.43	7.53	+0.11
Outer borough pct	4.83	4.95	+0.12
Manhattan pct	87.50	86.97	-0.53
Mean fare metered (USD)	19.66	19.74	+0.08
Mean distance metered (mi)	3.41	3.43	+0.02
Distance short pct	26.81	26.87	+0.06
Distance medium pct	67.63	67.36	-0.27

Distance long pct	5.55	5.77	+0.21
Credit share metered (pct)	86.33	86.16	-0.17

Tabla 6.2. Comparación D limpio vs M en las métricas históricas. La máxima diferencia absoluta es de 0.53 puntos porcentuales, confirmando que M preserva la estructura de D en todas las dimensiones validadas.

6.3 Cobertura completa de las 240 reglas de particionamiento

Se cubren 240 reglas pedidas por rúbrica en M, con una suma de celdas que iguala el tamaño de la muestra. No existen celdas vacías y el conteo mínimo de 53 registros asegura la representatividad de los estratos raros (airport x flex x late_night x short), preservados por el piso mínimo establecido.

pu_macro_zone	Filas en M
airport	378,943
manhattan	4,374,135
outer_borough	249,002
unknown	27,645
Total	5,029,725

Tabla 6.3. Subtotales por pu_macro_zone sobre las 240 reglas. Conteos por estrato: mínimo 53, mediana 803, máximo 681,296.

6.4 Ejemplos por regla de particionamiento

Documentamos cinco reglas representativas que cubren los perfiles cualitativamente distintos identificados en la sección 4. Los dos primeros (ejemplos 1 y 2) son estratos dominantes Manhattan-tarjeta con asignación proporcional pura sin intervención del piso. Los tres siguientes (ejemplos 3, 4 y 5) ilustran perfiles de aeropuerto, app-based nocturno y cuasi-imposible Port Authority.

Ejemplos 1 y 2: dominantes Manhattan x credit

El estrato manhattan|credit|other|medium representa el perfil típico del Yellow Taxi (13.64% de D, ~682,000 filas en M): trayectos en Manhattan, pago con tarjeta y distancia media en horario laboral no-pico. El segundo grupo más común, manhattan|credit|weekday_pm_peak|medium (10.76% de D), corresponde al pico de demanda vespertino (16-20 PM) identificado por Safikhani et al. 2020. Ambos estratos operan bajo asignación proporcional pura.

Ejemplo 3: airport | other | other | long

Viaje largo desde aeropuerto codificado en payment_type 3-4. El análisis de la sección 4.2 mostró que el bucket payment_group = other en este perfil se compone 80% de disputas y 20% de no-cargo. Una interpretación plausible es que los tickets altos generan más impugnaciones. Filas de muestra extraídas de M:

Pickup	PU	DO	Distancia	Tarifa	payment	Rate
2025-05-01 11:38	132	161	17.50	70.00	4	2
2025-05-01 11:21	132	223	15.10	64.60	3	1
2025-05-01 13:10	132	137	13.65	81.00	4	5

Tabla 6.4. Filas de muestra de la regla *airport | other | other | long*. PULocationID 132 corresponde a JFK Airport. Las tarifas planas alrededor de USD 70-80 y los payment_type 3/4 confirman el perfil.

Ejemplo 4: *outer_borough | flex | late_night | long*

Perfil consistente con uso app-based en outer boroughs durante la madrugada para viajes largos hacia aeropuerto o Manhattan. Ratio de dependencia 14.5x sobre el modelo de independencia. Filas de muestra:

Pickup	PU	DO	Distancia	Tarifa	payment	Rate
2025-05-01 00:49	49	235	15.44	49.80	0	99
2025-05-01 00:20	255	78	14.17	45.81	0	99
2025-05-01 00:34	108	186	12.58	52.01	0	99

Tabla 6.5. Muestra de la regla *outer_borough | flex | late_night | long*. Los PULocationID 49, 255 y 108 ubican los viajes en Brooklyn y el Bronx. El payment_type 0 y RatecodeID 99 identifican el régimen Flex Fare.

Ejemplo 5: *airport | flex | other | short*

Estrato cuasi-imposible (Port Authority prohíbe e-hail en aeropuertos). 59 filas en D conservadas completas en M por el piso mínimo. Sin piso, este perfil habría quedado representado por 3-4 filas, perdiendo la señal estadística. Las filas de muestra evidencian distancias muy cortas (menos de 1 mi, consistentes con errores de codificación de zona) y tarifas relativamente altas (USD 20 a 60), lo que sugiere registros residuales que combinan Flex Fare con anomalías operativas:

Pickup	PU	DO	Distancia	Tarifa	payment	Rate
2025-05-09 15:54	138	138	0.19	54.08	0	99
2025-05-12 14:58	132	132	0.59	61.99	0	99
2025-05-12 15:36	138	138	0.03	21.57	0	99

Tabla 6.6. Muestra de la regla *airport | flex | other | short* (JFK: 132, LaGuardia: 138). Los trayectos cortos (PU=DO < 1 mi) indican posibles errores de codificación o excepciones. Se preservan íntegros por el piso mínimo de la muestra.

El conjunto de cinco ejemplos cubre el rango cualitativo del estrato: dominante, pico, tarifa plana JFK, perfil app-based nocturno y cuasi-imposible Port Authority. La maquinaria de sampleBy opera uniformemente sobre las 240 reglas, conservando proporcionalmente los dominantes y elevando con piso mínimo los raros.

Referencias

- Donkor, F. (2020). Tip-creep: Defaults and dynamic tip rates in taxis [Working paper]. Stanford Graduate School of Business. <https://www.gsb.stanford.edu/faculty-research/working-papers/tip-creep-defaults-dynamic-tip-rates-taxis>
- Moorthy, P. (2025). Robust taxi fare prediction under noisy conditions (arXiv:2507.20008). arXiv. <https://arxiv.org/abs/2507.20008>
- New York City Taxi and Limousine Commission. (2013). HAIL market analysis. https://www.nyc.gov/assets/tlc/downloads/pdf/boro_taxi_market_study.pdf
- New York City Taxi and Limousine Commission. (2023). Flex Fare pilot evaluation report. https://www.nyc.gov/assets/tlc/downloads/pdf/flex_fare_pilot_report_09_2023.pdf
- New York City Taxi and Limousine Commission. (2025a). 2024 annual report. https://www.nyc.gov/assets/tlc/downloads/pdf/annual_report_2024.pdf
- New York City Taxi and Limousine Commission. (2025b). Data dictionary: Yellow taxi trip records. https://www.nyc.gov/assets/tlc/downloads/pdf/data_dictionary_trip_records_yellow.pdf
- New York City Taxi and Limousine Commission. (s.f.). TLC Factbook [Dashboard]. <https://www.nyc.gov/site/tlc/about/data.page>
- OpenAI. (2026). ChatGPT (basado en GPT-5.5 Thinking) [Modelo de lenguaje grande], utilizado para revisión cruzada de propuestas y validación de fórmulas estadísticas. <https://chat.openai.com/>
- Riascos, A. P., & Mateos, J. L. (2020). Networks and long-range mobility in cities: A study of more than one billion taxi trips in New York City. *Scientific Reports*, 10, 4022. <https://doi.org/10.1038/s41598-020-60875-w>
- Safikhani, A., Kamga, C., Mudigonda, S., Faghih, S. S., & Moghimi, B. (2020). Spatio-temporal modeling of yellow taxi demands in New York City using generalized STAR models. *International Journal of Forecasting*, 36(3), 1138-1148. <https://doi.org/10.1016/j.ijforecast.2019.08.003>