

Estimación de tarifa y arquetipos operativos en NYC Yellow Taxi

Aprendizaje supervisado y no supervisado sobre grandes volúmenes de datos

EQUIPO 12

Carlos Eduardo Vega Campos · Marco Emilio Jiménez Jiménez · Martha Alicia Villalobos Facundo · Jonathan Javier Monsalve Giraldo

MATERIA

Análisis de grandes volúmenes de datos (Grupo 10)
· Tecnológico de Monterrey

¿Qué queremos resolver?

89.9M

viajes Yellow Taxi (2024 y 2025), cerca de 1.42 GB en Parquet

DOS PREGUNTAS DE APRENDIZAJE

- 01 Supervisada:** ¿qué tan bien se estima la tarifa base con variables operativas?
- 02 No supervisada:** ¿existen arquetipos operativos estables en millones de viajes?

¿Por qué importa?: auditar tarifas, entender Flex Fare, resumir la operación en perfiles

Un problema de gran volumen

VOLUMEN

89.9M de registros, no caben cómodos en memoria de un solo nodo

HETEROGENEIDAD

Esquemas mensuales que cambian, regímenes tarifarios distintos, zonas de alta cardinalidad

DIMENSIÓN TEMPORAL

Dos años con estacionalidad y cambios regulatorios

HERRAMIENTA

Apache Spark para procesar el volumen completo

De los datos crudos a una base limpia

Fuente: registros públicos del TLC en formato Parquet

Limpieza e imputaciones por consistencia: se eliminan montos negativos, distancias no plausibles y viajes inconsistentes

Caracterización: zona de origen, grupo de pago, bucket de día y hora, bucket de distancia

RESULTADO DE LA LIMPIEZA

89.9M → 84.4M

viajes · 6.07% removido

HALLAZGO CLAVE

En viajes medidos por taxímetro, la correlación distancia-tarifa sube a **0.930** tras la limpieza

Una muestra que respeta la población

Muestreo estratificado proporcional con piso de 500 por estrato (no aleatorio simple)

240 ESTRATOS


4 zonas × 4 pagos × 5 horarios × 3 distancias

MUESTRA M

5,029,725 viajes

cubre los 240 estratos

Las medias y desviaciones globales se estabilizan antes de 50,000 registros; la representatividad se protege con los 240 estratos



Las curvas se aplanan antes de 50,000 registros

Dos modelos, dos preguntas

SUPERVISADO · RANDOM FOREST


Gana al baseline lineal. RMSE ~5 USD, MAE ~1.6 USD, R2 ~0.92

NO SUPERVISADO · KMEANS

5 clusters, gana a GMM en separación y balance

No aplican matriz de confusión ni ROC (no es clasificación): se usan RMSE, MAE, R2 y silueta

La señal se concentra en distancia, duración, zona y régimen tarifario



Importancia de variables del Random Forest


¿Los resultados son estables?

Validación de 5 folds sobre los modelos ya elegidos (no se rebuscan hiperparámetros)


RMSE de prueba entre **4.97 y 5.29**: variabilidad baja

Brecha train/test contenida: sin señales fuertes de sobreajuste

La **profundidad máxima 10** del Random Forest es el mejor compromiso



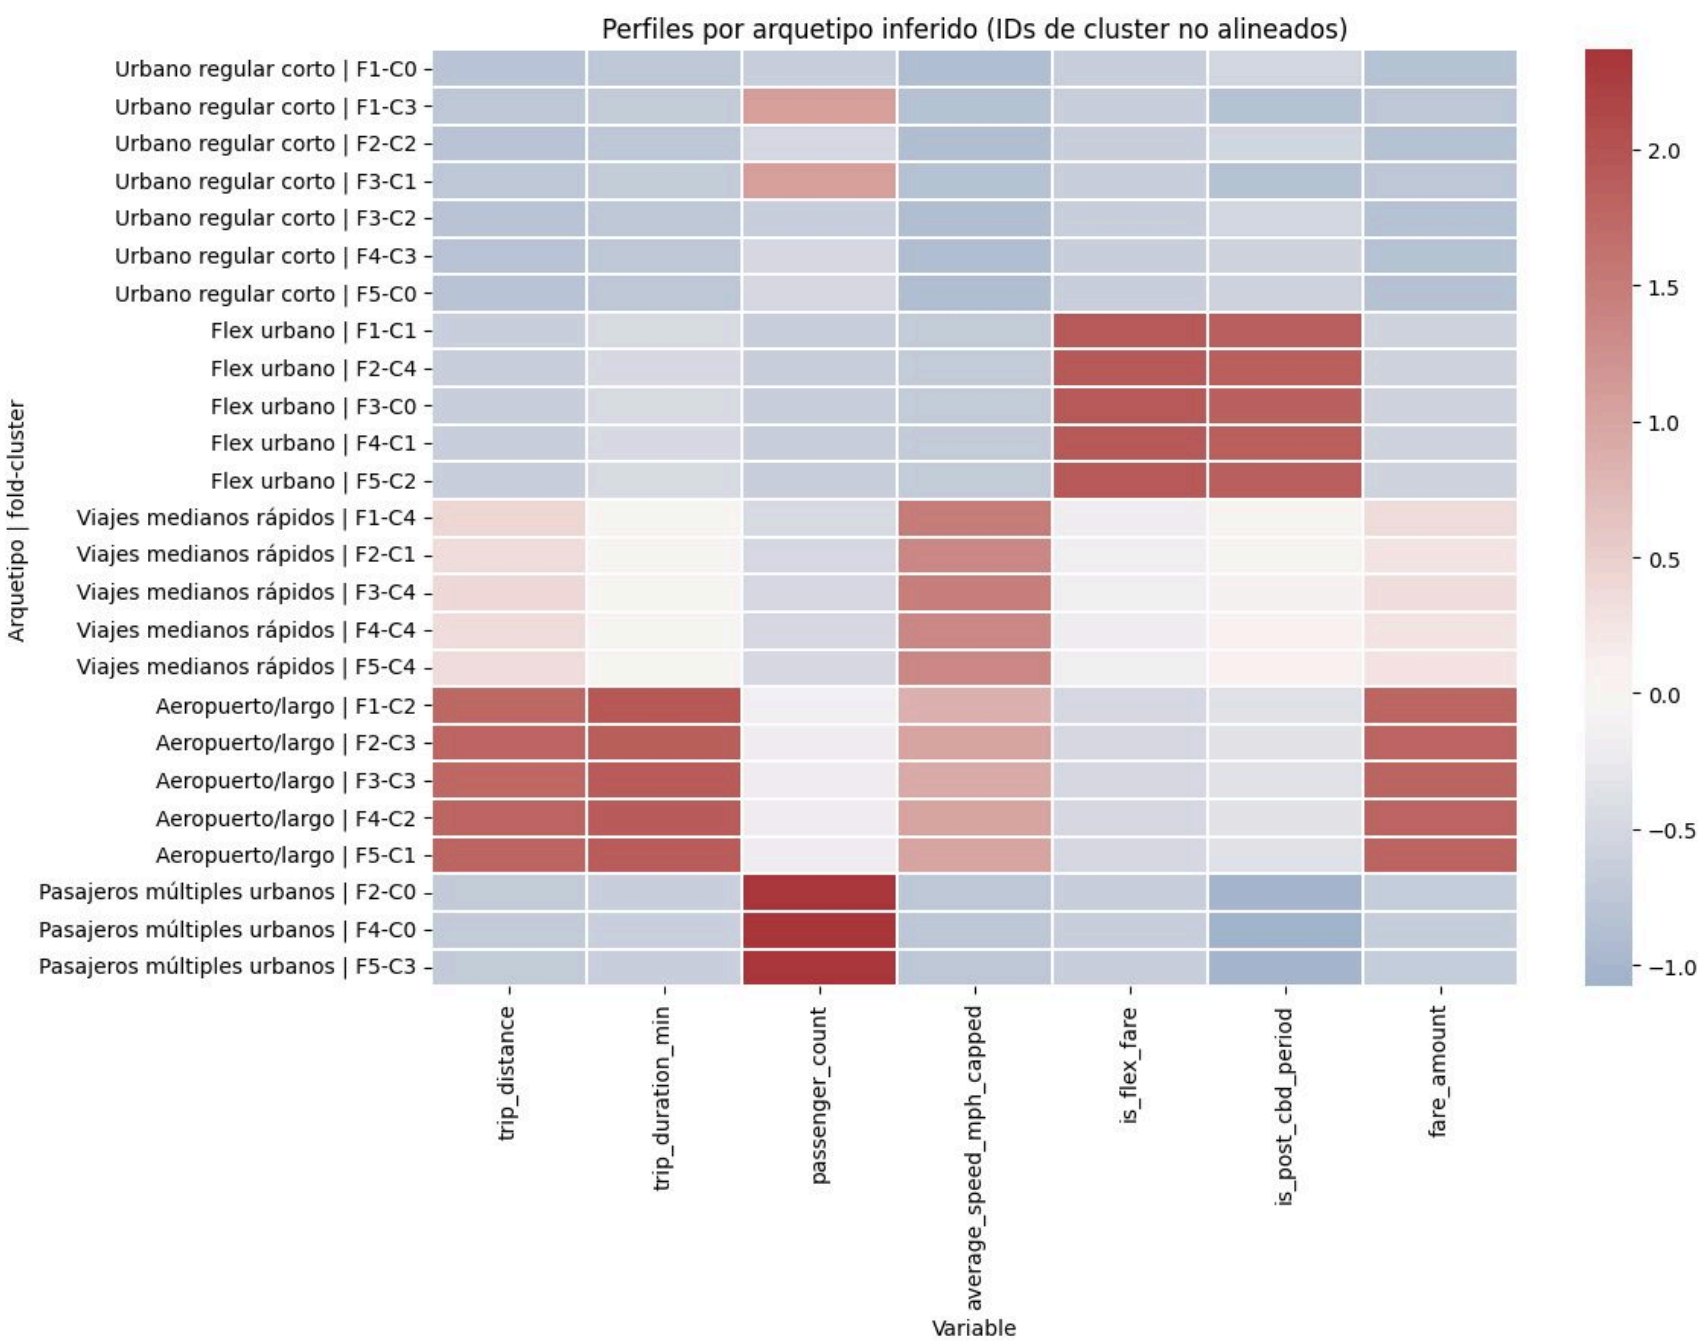
Métricas por fold



Curva de complejidad

¿Los arquetipos son estables entre folds?

Los mapas de calor de perfiles muestran que los arquetipos tienen señales operativas distintas




Perfiles por arquetipo inferido (IDs de cluster no alineados)

¿Dónde acierta y dónde falla el modelo?


La distribución predicha sigue a la real, incluido el pico de tarifa fija de aeropuerto

El error es bajo en tarifas medias y crece en la cola de 120 USD o más



Por segmento: Metered es más predecible que Flex Fare



Densidad real vs predicha



Error por rango de tarifa



Real vs predicho y residuales por segmento

RESULTADOS NO SUPERVISADOS


Cinco arquetipos operativos

La silueta se mantiene positiva en los 5 folds (~0.42 a 0.46), sin colapso de clusters


Aparecen cinco arquetipos: urbano regular corto, Flex urbano, mediano rápido, aeropuerto o largo, pasajeros múltiples urbanos

Cada cluster tiene una firma propia de distancia, duración, velocidad, Flex Fare y tarifa interpretativa

La tarifa se usa para interpretar perfiles, no para entrenar KMeans



Silueta por fold



Perfil de los arquetipos

¿Qué acota el modelo y cómo seguir?

01

Limitación: el error crece en tarifas altas, especialmente en la cola de 120 USD o más

Trabajo futuro: probar modelos por tramos o gradient boosting para capturar mejor esa cola

02

Limitación: Flex Fare es más difícil de estimar que Metered

Trabajo futuro: modelar por separado los regímenes tarifarios Metered y Flex Fare

03

Limitación: faltan variables externas como tráfico, clima, eventos, ruta exacta y reglas internas de apps

Trabajo futuro: incorporar esas fuentes para explicar mejor variabilidad no observada

¿Qué acota los arquetipos y cómo seguir?

01

Limitación: KMeans produce perfiles operativos, no clases oficiales del servicio

Trabajo futuro: validar los arquetipos con análisis de negocio o reglas operativas externas

02

Limitación: el arquetipo de pasajeros múltiples urbanos es el menos estable entre folds

Trabajo futuro: refinarlo con variables adicionales o una segunda segmentación dentro de viajes urbanos

03

Limitación: los clusters dependen de las variables observadas; faltan tráfico, clima, eventos y ruta exacta

Trabajo futuro: incorporar variables externas para separar mejor arquetipos parecidos

La tarifa se estima bien en la masa principal de viajes y KMeans resume la operación en cinco arquetipos interpretables

Arquetipos: urbano regular corto · Flex urbano · mediano rápido · aeropuerto o largo · pasajeros múltiples urbanos

El pipeline integra Spark, limpieza, muestreo estratificado, modelado y validación para convertir 84.4M de viajes limpios en evidencia accionable, con cautela en Flex Fare, tarifas extremas y arquetipos menos estables